实验一：新闻文本分类实验报告

姓名：徐健 学号：10245501464 日期：2026-09-24

一、最终方案和实验结果

最终方案：邮件头部信息删掉，用 TF-IDF 提取特征，设置最大词数 30000，只用一元词 unigram，最后搭一个只有一层隐藏层的 MLP，隐藏层设 100 个神经元。

数据集分层随机切分，随机种子固定 42，训练集 6000 条，验证集 1368 条。在这个划分下验证集准确率拿到 94.01%。换了 5 组不同随机种子重复跑实验，平均准确率 94.28%，波动 ±0.29%，macro-F1 分数 0.9404。对比朴素贝叶斯的基线 89.84%，差不多涨了 4.4 个百分点，提升明显。

二、数据集和数据预处理

这批原始文本是新闻组邮件数据，几乎全都带着邮件头，第一步就把这部分去掉。

一开始主观觉得文本里的“Re:”回帖标记、引用的旧内容都是没用的噪音，就把这部分删掉了。结果准确率反而从 91.89% 掉到 91.23%。后面猜测虽然整个数据集里面 67% 的样本都是回帖，但是不同新闻组回帖占比差得大。比如摩托车相关类别回帖率高达 81.8%，而硬件类只有 47.6%。所以说频率高，不代表就是没用的。要看它在不同类别里面出现的分布是不是不一样，有区分度就得留着。

停用词我也试过加上，但是准确率反而掉了 0.3 个百分点，干脆不用。因为 sklearn 自带的 TF-IDF 里面 IDF 计算公式本身就会压制那些出现超级频繁的词，停用词在这里收益不大。

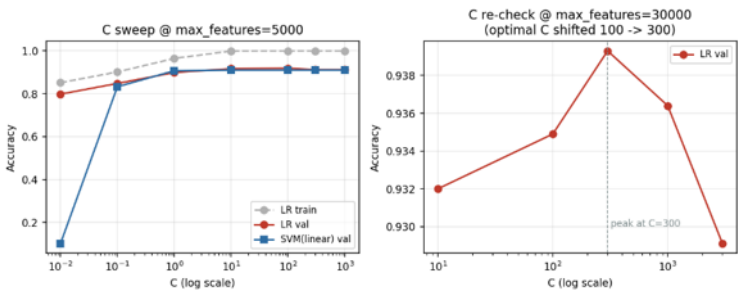
三、特征工程和调参踩坑

TF-IDF 就是词频乘逆文档频率。往上调最大词表数量，从 3000 加到 30000，验证集效果持续上涨，88.8% 涨到 93.5%。数据集原始一共大概 9.7 万个词，超过 30000 之后效果就不明显。 也尝试过用二元词 ngram (1,2)，没想到各个参数跑出来全是负收益，准确率往下掉。推测是很多没意义的词组占掉了特征名额，反而把真正有用的判别词挤掉了，所以最后只用一元词。

调正则化参数 C：C 取对数，在 0.01~1000 之间扫参（图 1）。逻辑回归和线性 SVM 中 C 含义相同，C 越大正则越弱。C=0.01 的时候明显欠拟合，训练和验证准确率才 10% 左右；C 慢慢变大，验证集效果先涨后降。 词特征只有 5000 的时候，逻辑回归最优 C 是 100，准确率 91.89%。但是把词表扩大到 30000 维之后，最优 C 直接漂移到 300，拿到 93.93%。这里学到，特征维度一变，正则参数必须重新调，不能直接沿用老参数。

MLP 网络结构我也做了几组对照实验：默认单隐层 100 个神经元就拿到 94.01% 的结果。

- 把隐藏层加宽到 200 个神经元：准确率只涨 0.14%，但是训练直接干到 95 分钟，时间成本太高；改成两层隐藏层 (100,50)，准确率反而跌了 0.59%，出现过拟合；
- 加大训练轮次 epochs，从 300 改到 1000，结果完全没变化。看损失曲线能看到，模型跑到第 93 轮就触发提前停止条件（n_iter_no_change=10），早就收敛了，再多迭代没有意义。



（图 1：C ，左图 5000 特征下完整拟合曲线；右图 30000 特征，最优 C 漂移到 300）

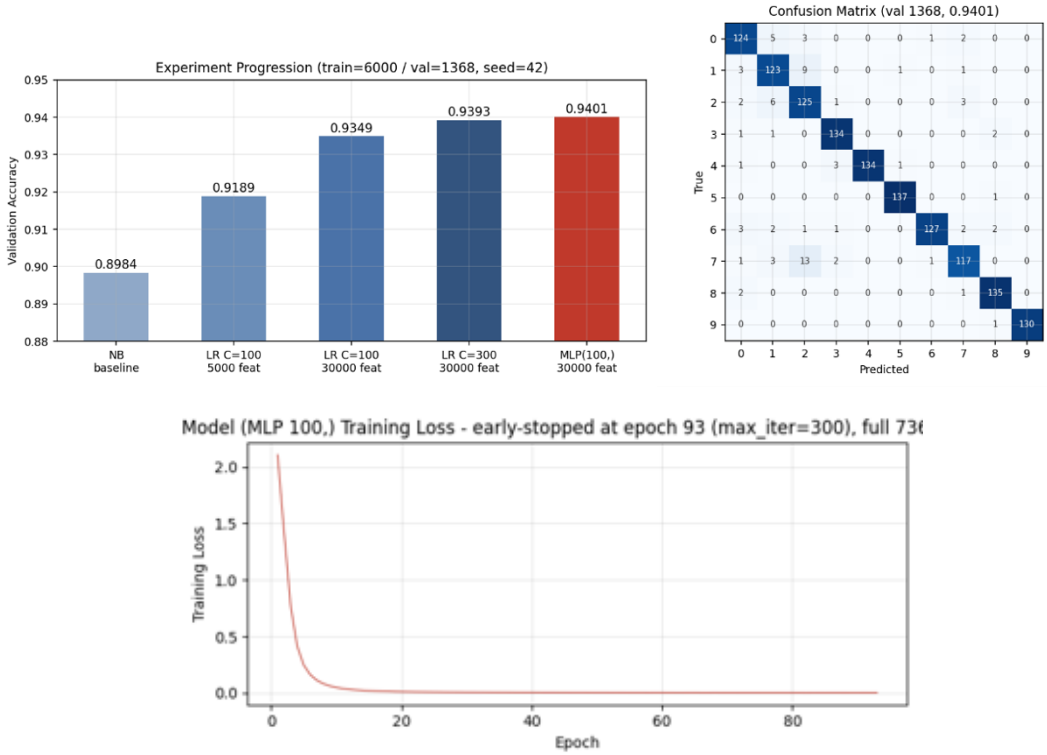
四、实验结果与分析

整个实验迭代提升路线(见图 2)：朴素贝叶斯基线 89.84%→LR(C=300, 30000 特征) 93.93%→MLP 单隐层 100 神经元 94.01%

看混淆矩阵（图 3）可以发现，主要错分集中在类别 0、1、2，分别对应图形、Windows、PC 硬件，这几个主题内容本身就很接近。线性模型权重看下来，出错大多来源于数据集本身内容重叠，不是模型的锅。

对比多个种子重复实验结果：逻辑回归平均 93.73%±0.55%，MLP 平均 94.28%±0.29%。5 次不同随机种子下 MLP 全部优于 LR，说明性能提升是模型本身带来的。 MLP(100,) 单层网络实际开销尚可，完整训练大概 10 分钟，换来稳定 0.5 个点提升，是值得的。

看 MLP 训练损失曲线（图 4，原始没平滑）：一开始损失 2.10，前 10 轮暴跌到 0.04，小批量 SGD 带来一些上下跳动属于正常现象。越往后波动越来越小，最后收敛到 0.0032。程序设置 max_iter=300，但实际第 93 轮就提前停止了。



（图 2：模型迭代准确率柱状图；图 3：验证集混淆矩阵；图 4：MLP 训练损失曲线）

五、实验结论 & 思考题

结论：固定随机种子 42 整套流程可以完全复现；测试集预测结果输出在 predictions.csv 文件。

思考 1：为什么线性模型在文本分类任务上效果经常很强？ 文本经过 TF-IDF 之后维度很高而且极度稀疏，很多情况下数据差不多接近线性可分；C 正则可以防止模型学一些莫名其妙的特例；同时 IDF 变换间接完成了特征缩放，所以线性模型表现很不错。

思考 2: MLP 还能不能继续往上刷分？过拟合风险怎么样？ 单纯加宽网络只能带来一点点提升，但训练时间暴涨；加深网络反而容易过拟合；单纯加大迭代轮数没用。对比训练集 99.98% 和验证集 94.3%，MLP 相比线性模型过拟合风险更高。

思考 3：其他文本表示方式简单聊聊 词袋 TF-IDF 完全丢掉语序信息；Word2Vec 得到词向量能捕捉语义，但是还要做一步聚合才能变成文档向量；BERT 效果理论最强，但针对这个数据集有点大材小用。